

Relatório de Inteligência Artificial Computacional: Modelos de Regressão e Classificação

Tiago Silveira Taumaturgo (2410518), Vinicius Lira Cavalcante (2314980),
William Wallace Sena Nogueira (2310284)

Abstract

Este relatório descreve a implementação e análise de modelos preditivos supervisionados divididos em duas etapas: regressão quantitativa e classificação qualitativa. Os modelos foram avaliados através de técnicas de validação cruzada e simulações de Monte Carlo para garantir a robustez dos resultados.

Index Terms

Inteligência Artificial, Regressão Linear, Classificação Gaussiana, MQO, Aprendizado Supervisionado.

I. INTRODUÇÃO

O PRESENTE trabalho foca no desenvolvimento de sistemas baseados em aprendizagem supervisionada, utilizando a minimização de funções de custo para o ajuste de parâmetros. A primeira etapa aborda a predição da potência de um aerogerador, enquanto a segunda utiliza sinais de eletromiografia (EMG) para classificação de expressões faciais. O código-fonte completo desenvolvido neste trabalho está disponível publicamente em: <https://github.com/tiagostmg/iac>.

II. METODOLOGIA

A. Tarefa de Regressão

A variável independente consiste na velocidade do vento, enquanto a variável dependente representa a potência gerada. Foram implementados os seguintes modelos:

- Média da variável dependente.
- Mínimos Quadrados Ordinários (MQO) Tradicional.
- MQO Regularizado (Tikhonov) com $\lambda \in \{0, 0.25, 0.5, 0.75, 1\}$.

A validação seguiu o método *Random Subsampling Validation* com $R = 500$ rodadas, utilizando 80% dos dados para treinamento e 20% para teste.

B. Tarefa de Classificação

A classificação das 5 expressões faciais utilizou os dados de dois sensores EMG (Corrugador do Supercílio e Zigomático Maior). Os modelos implementados foram:

- **MQO Tradicional:** Adaptado para múltiplas classes através da codificação *One-Hot Encoding* do vetor de rótulos. A classe predita é aquela que retorna o maior valor numérico na saída.
- **Classificadores Gaussianos:** Baseiam-se no Teorema de Bayes para calcular a probabilidade a posteriori $P(C_k|x)$. Assumem que a densidade de probabilidade de cada classe segue uma distribuição Normal Multivariada. As variações implementadas diferem na forma como a matriz de covariância (Σ) é tratada:
 - *Tradicional (QDA):* Calcula uma matriz de covariância Σ_k individual para cada classe, gerando fronteiras quadráticas.
 - *Covariâncias Iguais / Matriz Agregada (LDA):* Assume que todas as classes compartilham a mesma dispersão, utilizando uma matriz de covariância combinada Σ . Gera fronteiras estritamente lineares.
- **Naive Bayes:** Assume que os sensores (atributos) são estatisticamente independentes. Na prática, zera os elementos fora da diagonal principal da matriz de covariância Σ_k .
- **Classificador Gaussiano Regularizado (Friedman):** Utiliza um hiperparâmetro $\lambda \in [0, 1]$ para ponderar a matriz de covariância individual (Σ_k) e a matriz agregada (Σ). O valor ideal de λ foi encontrado utilizando *K-Fold Cross Validation* ($K = 10$).

A avaliação de robustez dos modelos foi realizada através de uma simulação de Monte Carlo com $R = 500$ rodadas (80% treino, 20% teste). A classificação dos 5 gestos faciais utilizou os sensores Corrugador do Supercílio e Zigomático Maior. Os modelos implementados foram:

- MQO Tradicional.
- Classificadores Gaussianos (Tradicional, Covariâncias Iguais, Matriz Agregada).
- Classificador de Bayes Ingênuo (Naive Bayes).
- Classificador Gaussiano Regularizado (Friedman), com hiperparâmetro λ definido via *k-fold cross validation*.

III. RESULTADOS E DISCUSSÃO

A. Análise Visual da Regressão

Conforme solicitado, a Figura 1 apresenta o gráfico de espalhamento dos dados do aerogerador.



Fig. 1. Relação entre Velocidade do Vento e Potência Gerada.

Observa-se um padrão não linear, assemelhando-se a uma curva sigmoide. Um modelo linear captura a tendência central, mas apresenta limitações naturais nas extremidades devido à natureza dos dados.

B. Desempenho em Regressão

Os modelos foram avaliados pelas métricas MSE (Erro Quadrático Médio) e R^2 ao longo de 500 rodadas. Os resultados estatísticos estão consolidados nas Tabelas I e II.

TABLE I
MÉTRICA DE ERRO QUADRÁTICO MÉDIO (MSE) - $R = 500$

Modelos	Média	Desvio-Padrão	Maior Valor	Menor Valor
Média da Var. Dep.	11084,99	645,95	13055,63	8845,41
MQO Tradicional	781,26	157,26	1312,03	413,95
MQO Regularizado (0,25)	796,54	171,33	1499,37	409,90
MQO Regularizado (0,50)	798,34	166,73	1493,50	461,87
MQO Regularizado (0,75)	799,14	165,00	1418,35	456,30
MQO Regularizado (1,00)	787,50	167,11	1537,29	463,69


TABLE II
MÉTRICA DE COEFICIENTE DE DETERMINAÇÃO (R^2) - $R = 500$

Modelos	Média	Desvio-Padrão	Maior Valor	Menor Valor
Média da Var. Dep.	-0,0027	0,0041	0,0000	-0,0362
MQO Tradicional	0,9294	0,0130	0,9591	0,8819
MQO Regularizado (0,25)	0,9281	0,0141	0,9624	0,8724
MQO Regularizado (0,50)	0,9285	0,0137	0,9576	0,8794
MQO Regularizado (0,75)	0,9281	0,0136	0,9569	0,8795
MQO Regularizado (1,00)	0,9291	0,0137	0,9564	0,8684

Análise Técnica: Ao analisar as Tabelas I e II, percebe-se que todos os modelos baseados em MQO apresentam um desempenho estatisticamente equivalente, com R^2 médio próximo a 0,929. Essa semelhança ocorre porque o particionamento aleatório dos dados é renovado a cada rodada, gerando flutuações normais que não indicam a superioridade de um λ específico. O alto valor de R^2 confirma que a velocidade do vento é um preditor robusto para a potência gerada.

Imagens/Tarefa de regressão/resumo_modelos_com_media.png

Fig. 2. Comparação de MSE e R^2 incluindo o modelo de média.



Imagens/Tarefa de regressão/resumo_modelos_sem_media.png

Fig. 3. Comparação detalhada entre variações do MQO.

C. Análise Visual e Desempenho em Classificação

O primeiro passo consistiu na visualização bidimensional dos dados de EMG, conforme ilustrado na Figura 4.



Fig. 4. Gráfico de Espalhamento: Sensores EMG (Zigomático Maior vs. Corrugador).

A Figura ?? revela uma forte sobreposição espacial entre as classes (alta densidade). A ausência de separabilidade linear clara entre as expressões faciais sugere, a priori, que modelos capazes de traçar fronteiras não-lineares poderiam obter melhor desempenho, embora devam ser cuidadosamente regularizados para evitar sobreajuste (*overfitting*) ao ruído das áreas de intersecção.

Para investigar essa dinâmica, as fronteiras de decisão de todos os classificadores foram plotadas, permitindo uma análise geométrica do comportamento de cada modelo. As Figuras 5 e 6 apresentam esses resultados.




Fig. 5. MQO Tradicional (Linear).



Fig. 6. Gaussiano Tradicional (Quadrático).




Fig. 7. Gaussiano: Covariâncias Iguais.



Fig. 8. Gaussiano: Matriz Agregada (LDA).




Fig. 9. Naive Bayes (Fronteiras Ortogonais).



Fig. 10. Friedman Ótimo ($\lambda = 0.05$).

Fica evidente que o Classificador Gaussiano Tradicional (Figura 6) consegue envolver as nuvens de dados de forma extremamente flexível, enquanto os modelos de Covariâncias Iguais e Matriz Agregada (Figuras 7 e 8) limitam-se a cortes lineares. O Naive Bayes (Figura 9) gera fronteiras com aspecto de "blocos" retangulares devido à pressuposição de independência entre os sensores.

Para encontrar o balanço ideal entre flexibilidade e estabilidade, o modelo Regularizado de Friedman foi otimizado via K-Fold ($K = 10$). Conforme a Figura 11, o ponto de máxima eficiência foi alcançado em $\lambda = 0.05$. O traçado suave do Friedman Ótimo pode ser observado na Figura 10.




Fig. 11. Variação da acurácia média em função de λ no modelo de Friedman.

Com o λ ótimo definido, procedeu-se à Simulação de Monte Carlo com 500 rodadas. Os resultados estatísticos estão consolidados na Tabela III e a distribuição das acurácias no boxplot da Figura 12.

TABLE III
RESULTADOS DA TAREFA DE CLASSIFICAÇÃO ($R = 500$)

Modelos	Média (%)	Desvio-Padrão (%)	Maior Valor (%)	Menor Valor (%)
MQO Tradicional	72,39	0,66	74,10	70,33
Gaussiano Tradicional	80,00	0,37	81,27	78,90
Gaussiano (Cov. Igual)	94,85	0,27	95,56	93,97
Gaussiano (Agregada)	96,27	0,18	96,73	95,72
Naive Bayes	79,86	0,37	81,07	78,76
Friedman ($\lambda = 0.05$)	99,74	0,04	99,89	99,63



Imagens/Tarefa de classificaÃ§Ã£o/boxplot_montecarlo.png

Fig. 12. Distribui  o de Acur  cias da Simula  o de Monte Carlo.

An  lise T  cnica: Os dados revelam um comportamento fundamentado na teoria estat  stica: estimar covari  ncias individuais para classes muito sobrepostas (Gaussiano Tradicional, 80,00%) resultou em um desempenho muito inferior aos modelos de covari  ncia compartilhada (Matriz Agregada, 96,27%). Isso indica que o Gaussiano Tradicional sofreu grave sobreajuste    vari  ncia local. O MQO apresentou o pior desempenho (72,39%) devido ao conhecido problema de mascaramento em classifica  es multiclasse projetadas linearmente. O modelo de Friedman sobressaiu-se com not  veis 99,74% de acur  cia m  dia e desvio-padr  o   nfimo (0,04%), evidenciando que uma penaliza  o leve ($\lambda = 0.05$) combinada    matriz agregada foi suficiente para estabilizar a invers  o das matrizes sem perder o poder de tra  ar fronteiras el  pticas ideais.

IV. CONCLUS  ES

Os resultados demonstram que modelos de regress  o linear baseados em MQO s  o altamente eficazes para o aerogerador, explicando mais de 92% da vari  ncia dos dados. Devido    natureza estoc  stica da valida  o, os modelos MQO apresentaram desempenho equivalente, evidenciando que o sistema    robusto a diferentes configura  es de regulariza  o neste conjunto de dados.

Na tarefa de classifica  o de dados de eletromiografia (EMG), a topologia densa e sobreposta das classes exigiu formula  es n  o-lineares. Observou-se que o excesso de graus de liberdade no Classificador Gaussiano Tradicional prejudicou a generaliza  o (80,00%). A aplica  o da regulariza  o de Friedman demonstrou ser um mecanismo poderoso: ao mesclar 5% de influ  ncia da matriz agregada    covari  ncia individual ($\lambda = 0.05$), o modelo atingiu quase a perfei  o preditiva (99,74% de acur  cia) com varia  o praticamente nula. Conclui-se que o equil  brio cuidadoso entre vi  s e vari  ncia, mediado por valida  o cruzada rigorosa (K-Fold),    indispens  vel para o sucesso de modelos de Intelig  ncia Artificial em dados biol  gicos estoc  sticos.

REFERENCES

- [1] P. C. S. Barbosa, "Trabalho Computacional: Modelos de Regress  o e Classifica  o," UNIFOR, 2026.