

Relatório de Inteligência Artificial Computacional: Redes Neurais Artificiais

Tiago Silveira Taumaturgo (2410518), Vinicius Lira Cavalcante (2314980),
William Wallace Sena Nogueira (2310284)

Resumo

Este relatório apresenta a implementação e a análise de redes neurais artificiais aplicadas a dois problemas supervisionados. A primeira etapa aborda a classificação binária do conjunto *spiral_d*, com estudo de underfitting e overfitting em Perceptron de Múltiplas Camadas (MLP). A segunda etapa trata do reconhecimento facial multiclasse com 20 pessoas, a partir do redimensionamento das imagens para 30×30 pixels e codificação *one-hot* bipolar. Conforme a orientação adotada neste relatório, as discussões relativas à Rede de Função de Base Radial (RBF) foram desconsideradas, concentrando a análise em Perceptron Simples, ADALINE e MLP.

Index Terms

Inteligência Artificial Computacional, Redes Neurais Artificiais, Perceptron, ADALINE, MLP, Reconhecimento Facial.

I. INTRODUÇÃO

ESTE trabalho tem como objetivo validar a implementação de modelos neurais lineares e não lineares em dois cenários distintos. Na etapa 1, o problema consiste em classificar duas espirais entrelaçadas, um caso clássico de separação não linear. Na etapa 2, o objetivo é reconhecer 20 indivíduos distintos em um conjunto de 640 imagens faciais.

O código-fonte utilizado na construção deste relatório encontra-se no repositório do projeto e, para esta versão do documento, foram considerados principalmente os artefatos gerados por `main_pt1_edit_sem_rfb.py` e `main_pt2.py`. Seguindo a solicitação adotada na elaboração do texto, as referências à arquitetura RBF foram omitidas da análise.

II. METODOLOGIA

A. Etapa 1: Classificação Binária no *spiral_d*

O conjunto *spiral_d* foi lido a partir de arquivo CSV, com duas variáveis de entrada e um rótulo binário por amostra. Os rótulos foram convertidos para codificação bipolar $\{-1, +1\}$, e os dados foram particionados em 80% para treinamento e 20% para teste a cada rodada. A normalização foi realizada por reescalonamento bipolar com base apenas no conjunto de treinamento.

Os modelos avaliados nesta etapa foram:

- **Perceptron Simples:** taxa de aprendizagem 0,01 e máximo de 300 épocas.
- **ADALINE:** taxa de aprendizagem 0,01, precisão 10^{-4} e máximo de 300 épocas.
- **MLP:** topologia base $[10, 6]$, taxa de aprendizagem 0,02, precisão 10^{-4} e máximo de 400 épocas.

Para investigar underfitting e overfitting na MLP, foram testadas três topologias:

- **Underfitting:** $[2]$, 200 épocas.
- **Ajuste intermediário:** $[10, 6]$, 400 épocas.
- **Overfitting:** $[24, 18, 12]$, 500 épocas.

A validação dos modelos foi feita por simulação de Monte Carlo com $R = 500$ rodadas. Em cada rodada foram calculadas as métricas acurácia, sensibilidade, especificidade, precisão e F_1 -score. Para as rodadas de maior e menor acurácia, foram salvas também as curvas de aprendizado e as matrizes de confusão.

B. Etapa 2: Reconhecimento Facial Multiclasse

Na segunda etapa foi utilizado o conjunto `RecFac`, composto por 640 imagens de faces distribuídas em 20 classes. Cada imagem original foi convertida para tons de cinza, redimensionada para 30×30 pixels e vetorizada, resultando em 900 atributos por amostra. A matriz de entrada foi organizada no formato $X \in \mathbb{R}^{900 \times 640}$ e a matriz de saídas no formato bipolar *one-hot*, com $Y \in \mathbb{R}^{20 \times 640}$.

Os hiperparâmetros escolhidos foram:

- **ADALINE:** taxa de aprendizagem 0,01, precisão 10^{-5} e máximo de 500 épocas.

- **MLP:** uma camada oculta com 50 neurônios, taxa de aprendizagem 0,1, precisão 10^{-5} e máximo de 500 épocas.

Para os tópicos de inspeção visual do enunciado, foram executadas 10 rodadas de Monte Carlo com particionamento 80/20, registrando a melhor e a pior acurácia de cada modelo, juntamente com suas curvas de aprendizado e matrizes de confusão. Para a análise estatística final, foram utilizadas 100 rodadas, calculando-se média, desvio-padrão, maior valor e menor valor da acurácia.

III. RESULTADOS E DISCUSSÃO

A. Etapa 1: Espirais Bidimensionais

A visualização inicial do conjunto *spiral_d* mostra duas classes com forte interdependência geométrica e separação nitidamente não linear, o que já antecipa a limitação dos modelos estritamente lineares.




Figura 1. Visualização inicial do conjunto *spiral_d*.

O estudo de complexidade da MLP confirmou esse comportamento. Na configuração subdimensionada, a curva de aprendizado decresce lentamente e estabiliza em patamar mais alto de erro, evidenciando capacidade insuficiente para representar a estrutura espiral. Já a configuração intermediária reduz o EQM de forma rápida e estável, enquanto a topologia superdimensionada continua reduzindo o erro por mais épocas, com maior flexibilidade do modelo.




Figura 2. MLP com underfitting.




Figura 3. MLP com ajuste intermediário.




Figura 4. MLP com maior complexidade.

Na validação por Monte Carlo, a diferença entre os modelos ficou evidente. O boxplot de acurácia indica que o Perceptron Simples apresentou a pior distribuição e grande dispersão, o ADALINE obteve melhora moderada, mas continuou limitado pela linearidade, e a MLP concentrou os resultados mais altos e mais estáveis. Isso é coerente com a natureza do problema: as espirais exigem fronteiras não lineares, o que favorece a MLP.




Figura 5. Distribuição da acurácia na etapa 1 ao longo das rodadas de Monte Carlo.

As matrizes de confusão de melhor caso reforçam esse diagnóstico. Enquanto o ADALINE ainda mantém quantidade relevante de falsos positivos sobre a classe -1 , a MLP atinge separação praticamente perfeita no melhor cenário observado, evidenciando ganho expressivo de representação.




Figura 6. ADALINE: melhor matriz de confusão.




Figura 7. MLP: melhor matriz de confusão.

Análise técnica: a etapa 1 funcionou como validador das implementações. Os resultados visuais e estatísticos mostram que os modelos lineares não conseguem capturar adequadamente o traçado das espirais, mesmo quando treinados por várias rodadas. A MLP, por outro lado, apresentou desempenho superior e baixa variabilidade, o que confirma que a escolha de uma topologia oculta moderada foi suficiente para representar a não linearidade do problema sem necessidade de recorrer à arquitetura RBF.

B. Etapa 2: Reconhecimento Facial

A Figura 6 apresenta um exemplo de imagem facial após o redimensionamento para 30×30 , escolha que equilibra redução de dimensionalidade com preservação dos traços principais de face.




Figura 8. Exemplo de amostra redimensionada para 30×30 pixels.

Os resultados de 100 rodadas de Monte Carlo estão sumarizados na Tabela I. Como solicitado neste relatório, a coluna referente à RBF foi desconsiderada nas discussões. Observa-se que tanto ADALINE quanto MLP alcançaram acurácia média acima de 97%, com vantagem para a MLP tanto na média quanto na estabilidade.

Tabela I
RESULTADOS DA ETAPA 2 PARA ACURÁCIA ($R = 100$)

Modelo	Média	Desvio-Padrão	Maior Valor	Menor Valor
ADALINE	0,9723	0,0148	1,0000	0,9375
MLP	0,9780	0,0138	1,0000	0,9297

O boxplot das 100 rodadas mostra distribuições muito próximas para ADALINE e MLP, mas a rede MLP aparece com mediana ligeiramente superior. Isso indica que, mesmo após forte redução de dimensionalidade, a presença de uma camada oculta ainda oferece um pequeno ganho na capacidade discriminativa entre as 20 identidades.




Figura 9. Distribuição da acurácia na etapa 2.

Nas matrizes de confusão de melhor caso, os dois modelos apresentam diagonal principal dominante, com pouquíssimos erros fora dela. Já nos piores casos, os erros continuam esparsos e parecem concentrar-se em identidades específicas, sugerindo que determinadas faces compartilham padrões visuais semelhantes após o redimensionamento. Em particular, aparecem trocas pontuais envolvendo classes como *glickman*, *karyadi*, *bpm*, *mitchell* e *tammo*, mas sem colapso global do classificador.




Figura 10. ADALINE: melhor caso.




Figura 11. ADALINE: pior caso.




Figura 12. MLP: melhor caso.




Figura 13. MLP: pior caso.

Análise técnica: os resultados da etapa 2 mostram que o problema de reconhecimento facial, embora multiclasse, ficou bem condicionado após o redimensionamento para 30×30 . O ADALINE já obteve excelente desempenho, o que sugere que boa parte das classes tornou-se aproximadamente separável no espaço de atributos adotado. A MLP superou levemente esse resultado ao incorporar uma camada oculta com 50 neurônios, preservando alta taxa de acerto e baixa variabilidade. Em outras palavras, a não linearidade adicional foi útil, mas o ganho ocorreu sobre uma base já bastante forte.

IV. CONCLUSÕES

Os experimentos confirmam a adequação das implementações neurais nas duas etapas propostas. No problema *spiral_d*, os modelos lineares mostraram limitações claras diante de uma fronteira altamente não linear, enquanto a MLP apresentou o melhor compromisso entre capacidade de representação e estabilidade estatística. O estudo de underfitting e overfitting foi importante para mostrar que a escolha da topologia interfere diretamente na qualidade da convergência.

No reconhecimento facial multiclasse, a estratégia de redimensionar as imagens para 30×30 pixels e codificar as saídas em *one-hot* bipolar produziu resultados muito fortes. Tanto ADALINE quanto MLP atingiram acurácia média superior a 97%, com ligeira vantagem para a MLP. Assim, conclui-se que a arquitetura multicamada foi a mais consistente no conjunto de experimentos analisados, ao mesmo tempo em que a exclusão da RBF não comprometeu a interpretação dos resultados principais do trabalho.

REFERÊNCIAS

- [1] P. C. S. Barbosa, “Trabalho Computacional AV2: Redes Neurais Artificiais,” UNIFOR, 2026.