

Relatório de Inteligência Artificial Computacional: Busca e Otimização Meta-heurística

Tiago Silveira Taumaturgo (2410518), Vinicius Lira Cavalcante (2314980),
William Wallace Sena Nogueira (2310284)

Resumo

Este relatório aborda a aplicação de algoritmos de busca local e heurísticas evolutivas na resolução de problemas contínuos e discretos. A primeira etapa é dedicada à otimização contínua de funções-custo clássicas por meio de abordagens de subida de encosta (Hill Climbing), busca aleatória local (LRS) e busca aleatória global (GRS). A segunda etapa foca na resolução de problemas discretos e combinatórios complexos, utilizando Têmpera Simulada (Simulated Annealing) genérica para o problema clássico das 8-Rainhas e Algoritmos Genéticos (GA) para o Caixeiro Viajante 3D (TSP) com drone baseado na base oficial de grupos. Por fim, investiga-se a otimização contínua multivariada na função Rastrigin de 50 dimensões comparando o GA não-canônico à Têmpera Simulada sob critérios de custo computacional e de armazenamento em memória. O repositório contendo todo o código-fonte desenvolvido está disponível em: <https://github.com/tiagostmg/iac>.

Index Terms

Inteligência Artificial Computacional, Busca Local, Têmpera Simulada, Algoritmos Genéticos, Crossover SBX, Caixeiro Viajante.

I. INTRODUÇÃO

OS métodos de busca e otimização meta-heurísticos constituem uma classe de algoritmos de fundamental relevância na resolução de problemas de engenharia e logística cujos espaços de estados são complexos, multimodais ou NP-difíceis. Este trabalho relata o desenvolvimento, a análise empírica e a comparação de técnicas clássicas de busca local (Hill Climbing, LRS, GRS), da Têmpera Simulada (Simulated Annealing - SA) e de variantes de Algoritmos Genéticos (GA).

O documento está estruturado de modo a descrever a metodologia adotada em cada etapa e expor os resultados das simulações computacionais. O código-fonte que gerou as análises e gráficos deste relatório é implementado sem dependência de bibliotecas de otimização prontas (implementação *from scratch*), priorizando os preceitos de modularidade e reprodutibilidade científica.

II. METODOLOGIA

Esta etapa investiga o comportamento de três algoritmos clássicos de busca local em espaços contínuos bidimensionais: Subida de Encosta (*Hill Climbing* - HC), Busca Aleatória Local (*Local Random Search* - LRS) e Busca Aleatória Global (*Global Random Search* - GRS). Os testes foram conduzidos sobre 6 funções matemáticas com características distintas de multimodalidade e restrições de domínio, conforme descritas a seguir:

- 1) **Função 1 (Esférica - Minimização):** $f_1(x) = x_1^2 + x_2^2$, com $x_i \in [-100, 0, 100, 0]$. Possui um único mínimo global em $x = (0, 0)$ com $f_1(x) = 0$.
- 2) **Função 2 (Exponencial - Maximização):** $f_2(x) = \exp(-(x_1^2 + x_2^2)) + 2 \exp(-((x_1 - 1,7)^2 + (x_2 - 1,7)^2))$, com $x_1 \in [-2, 0, 4, 0]$, $x_2 \in [-2, 0, 5, 0]$. Apresenta um máximo local em $(0, 0)$ com $f_2(0, 0) = 1$ e o máximo global em $(1,7, 1,7)$ com $f_2(1,7, 1,7) \approx 2$.
- 3) **Função 3 (Ackley 2D - Minimização):** $f_3(x) = -20 \exp\left(-0,2\sqrt{0,5(x_1^2 + x_2^2)}\right) - \exp(0,5(\cos(2\pi x_1) + \cos(2\pi x_2))) + 20 + e^1$, com $x_i \in [-8, 0, 8, 0]$. Altamente multimodal, com mínimo global em $(0, 0)$ com $f_3(x) = 0$.
- 4) **Função 4 (Rastrigin 2D - Minimização):** $f_4(x) = (x_1^2 - 10 \cos(2\pi x_1) + 10) + (x_2^2 - 10 \cos(2\pi x_2) + 10)$, com $x_i \in [-5, 12, 5, 12]$. Apresenta diversos mínimos locais dispostos em grade regular, com mínimo global em $(0, 0)$ com $f_4(x) = 0$.
- 5) **Função 5 (Exponencial Multimodal - Maximização):** $f_5(x) = \frac{x_1 \cos(x_1)}{20} + 2 \exp(-x_1^2 - (x_2 - 1)^2) + 0,01x_1x_2$, com $x_i \in [-10, 0, 10, 0]$. Possui uma agulha estreita de máximo global próximo a $(0, 1)$ e um máximo local secundário no platô plano.
- 6) **Função 6 (Senoidal Oscilatória - Maximização):** $f_6(x) = x_1 \sin(4\pi x_1) - x_2 \sin(4\pi x_2 + \pi) + 1$, com $x_i \in [-1, 0, 3, 0]$.

Os algoritmos de busca foram estruturados da seguinte forma:

- **Hill Climbing (HC):** Inicia em uma posição aleatória no domínio e realiza perturbações uniformes na vizinhança dentro de uma caixa definida pelo parâmetro ϵ : $x_{cand} \sim U(x_{opt} - \epsilon, x_{opt} + \epsilon)$. A transição ocorre se $f(x_{cand})$ for melhor que $f(x_{opt})$.

- **Local Random Search (LRS):** A perturbação baseia-se em uma distribuição Gaussiana multidimensional adicionada ao ponto atual: $x_{cand} = x_{opt} + \eta$, onde $\eta \sim N(0, \sigma^2 I)$ e σ representa a largura do passo.
- **Global Random Search (GRS):** Amostra candidatos de maneira uniforme em todo o domínio de busca, sem utilizar informações de localidade.

Para conter a busca dentro dos domínios válidos, aplica-se o operador de saturação (*clipping*) nas bordas. O limite de iterações por execução foi fixado em 1000, e adotou-se um critério de parada antecipada caso não ocorra melhoria após 100 iterações consecutivas. Foram conduzidas 100 simulações completas para cada configuração de parâmetros de modo a extrair a Moda e a Média estatística de convergência de cada método.

A. Etapa 2: Problemas de Otimização Discreta e Combinatória

1) 2.1: *Problema das 8-Rainhas (Têmpera Simulada):* O problema clássico das 8-Rainhas tem por objetivo posicionar 8 rainhas em um tabuleiro 8×8 de forma que nenhuma delas se ataque mutuamente. A representação do cromossomo adota um vetor $x \in \{1, \dots, 8\}^8$, em que o índice representa a coluna do tabuleiro e o valor a linha correspondente daquela rainha.

Para isso, implementou-se uma classe genérica *TemperaSimulada* com suporte a maximização ou minimização e perturbação flexível. A função heurística $h(x)$ calcula a quantidade total de ataques existentes no tabuleiro. A função objetivo (fitness) a ser maximizada é dada por:

$$f(x) = 28 - h(x) \quad (1)$$

onde 28 representa a quantidade máxima possível de pares de rainhas sem ataques mútuos.

A função de perturbação perturba apenas uma coluna aleatória para uma linha distinta da atual, restringindo a busca na vizinhança imediata. A temperatura decai de acordo com a regra de resfriamento geométrico:

$$T_{t+1} = \alpha \cdot T_t \quad (2)$$

com $T_0 = 10,0$ e $\alpha = 0,95$. O algoritmo é executado de forma iterativa até que o conjunto de soluções únicas atinja todas as 92 soluções globais válidas do problema ($f(x) = 28$).

2) 2.2: *Problema do Caixeiro Viajante 3D (Algoritmo Genético):* O problema do Caixeiro Viajante (TSP) tridimensional modela a trajetória de menor distância percorrida por um drone de entrega a partir de uma origem $(0, 0, 0)$ visitando todos os pontos e retornando à origem.

A modelagem utilizou a base de dados oficial contida no arquivo *CaixeiroGruposGA.csv*. Para a simulação, selecionou-se os pontos da primeira região (Grupo ID = 1), totalizando $N_{pontos} = 40$ pontos de entrega mais o ponto de partida (origem), o que preenche o requisito de tamanho de problema de $30 < N_{pontos} < 60$.

A população foi fixada em $N_{pop} = 100$ indivíduos e a execução máxima em 500 gerações. O operador de seleção adota o método do Torneio com $k = 3$. Para a etapa de recombinação (crossover), devido ao caráter combinatório da cadeia de cidades (sem repetição de vértices), utilizou-se o *Order Crossover* (OX1) de dois pontos de corte aleatórios. A mutação ocorre por troca (*Swap*) de posição entre dois genes selecionados com taxa de 1%. A condição de parada antecipada (*early stopping*) foi parametrizada para 50 gerações consecutivas sem melhoria no custo global. Realizou-se $R = 30$ simulações de Monte Carlo avaliando o comportamento do algoritmo sob duas condições de elitismo:

- **Com Elitismo:** Preservação de $N_e = 5$ melhores indivíduos.
- **Sem Elitismo:** Recombinação global livre de herança direta.

3) 2.3: *Comparação de Métodos para Otimização da Função Rastrigin ($n = 50$):* A função de Rastrigin contínua é altamente multimodal e definida em n dimensões por:

$$f(x) = 10n + \sum_{i=1}^n (x_i^2 - 10 \cos(2\pi x_i)) \quad (3)$$

Para $n = 50$ no domínio $x_i \in [-5, 12, 5, 12]$, a busca pelo mínimo global em $x = (0, \dots, 0)$ com $f(x) = 0$ representa um alto desafio devido aos múltiplos mínimos locais.

Avaliou-se um Algoritmo Genético Não-Canônico com crossover real do tipo *Simulated Binary Crossover* (SBX) com $\eta = 1,0$ e taxa de cruzamento de 90%, e mutação Gaussiana contínua (desvio padrão $\sigma = 0,5$ e taxa de mutação de 2%). O impacto da população foi verificado sob os tamanhos 20, 50, 100 e 150 com limite de 300 gerações.

Os resultados do GA foram comparados com a Têmpera Simulada contínua, usando a mesma classe genérica, temperatura inicial $T_0 = 50,0$, taxa de decaimento $\alpha = 0,9998$, perturbação por ruído gaussiano ($\sigma = 0,05$) e limite de 30.000 iterações (o que equivale ao mesmo número de avaliações da função objetivo feitas pelo GA com população 100 ao longo de 300 gerações).

III. RESULTADOS E DISCUSSÃO

A. Etapa 1: Resultados das Funções de Custo Contínuas

A Tabela I e a Tabela II consolidam os resultados estatísticos obtidos após 100 rodadas de Monte Carlo para os algoritmos Hill Climbing (HC), Local Random Search (LRS) e Global Random Search (GRS) sob diferentes configurações de perturbação (ϵ para HC e σ para LRS).

Tabela I
COMPARAÇÃO DE CONVERGÊNCIA (FUNÇÕES 1, 2 E 3) EM 100 RODADAS

Função	Configuração	Hill Climbing		LRS		GRS	
		Moda	Média	Moda	Média	Moda	Média
Função 1 (Minimização)	$\epsilon = 0,1, \sigma = 0,5$	13999,2	13843,0445	0,0004	0,0034	125,4731	75,8083
	$\epsilon = 0,25, \sigma = 0,5$	6311,4	6779,9388	0,0002	0,0028	1,0113	63,2279
	$\epsilon = 2,0, \sigma = 0,5$	0,0	0,0286	0,0	0,0030	16,0831	71,2239
Função 2 (Maximização)	$\epsilon = 0,1, \sigma = 0,5$	1,0	1,0063	2,0	1,6789	2,0	1,8554
	$\epsilon = 0,25, \sigma = 0,5$	1,0	1,0059	2,0	1,7596	2,0	1,8646
	$\epsilon = 0,75, \sigma = 0,5$	1,0	1,0022	2,0	1,6190	2,0	1,8919
	$\epsilon = 1,5, \sigma = 0,5$	2,0	1,9591	2,0	1,8389	2,0	1,8637
Função 3 (Minimização)	$\epsilon = 0,1, \sigma = 0,5$	16,0	15,9601	0,1	0,4968	2,7	2,9523
	$\epsilon = 0,25, \sigma = 0,5$	16,0	15,9606	0,1	0,5081	2,8	3,0230
	$\epsilon = 0,75, \sigma = 0,5$	16,0	15,9612	0,1	0,4211	3,4	2,9818
	$\epsilon = 1,0, \sigma = 0,5$	0,1	0,4443	0,2	0,4962	2,7	3,0353

Tabela II
COMPARAÇÃO DE CONVERGÊNCIA (FUNÇÕES 4, 5 E 6) EM 100 RODADAS

Função	Configuração	Hill Climbing		LRS		GRS	
		Moda	Média	Moda	Média	Moda	Média
Função 4	$\epsilon = 1,0, \sigma = 0,5$	1,2	3,3899	2,2	4,0908	5,0	4,3091
Função 5 (Maximização)	$\epsilon = 0,1, \sigma = 0,5$	1,4	1,4370	1,0	0,9569	1,4	1,3724
	$\epsilon = 2,0, \sigma = 0,5$	1,4	1,4367	0,5	1,0133	1,3	1,4264
	$\epsilon = 5,0, \sigma = 0,5$	1,4	1,4353	1,0	0,9847	1,4	1,4151
	$\epsilon = 11,0, \sigma = 0,75$	1,4	1,4747	1,0	1,0001	1,4	1,4249
Função 6 (Maximização)	$\epsilon = 2,0, \sigma = 0,6$	3,6	4,4369	5,7	4,9981	5,1	4,8955
	$\epsilon = 2,5, \sigma = 0,75$	3,6	4,5256	5,6	4,9069	5,1	4,9212

A análise detalhada dos resultados revela como as perturbações e as topologias influenciam o desempenho de cada método:

- **Impacto da Distância de Perturbação (ϵ e σ):**

- Na **Função 1** (domínio plano gigante $[-100, 100]^2$), o Hill Climbing com pequenos passos ($\epsilon = 0,1$ e $0,25$) fica retido longe do mínimo global (13999,2 e 6311,4, respectivamente) por limite de iterações. Ao ampliar a perturbação para $\epsilon = 2,0$, HC alcança convergência quase perfeita ao mínimo (Moda 0,0). Em contrapartida, a LRS com perturbação Gaussiana ($\sigma = 0,5$) converge de forma robusta para próximo de zero em todas as rodadas (Moda $\leq 0,0004$), beneficiando-se das caudas da distribuição normal que permitem saltos de magnitude variada.
- Na **Função 2**, que possui um pico local de valor 1,0 na origem (0,0) e o ótimo global de valor 2,0 em (1,7, 1,7), o Hill Climbing com passos curtos ($\epsilon \leq 0,75$) é invariavelmente capturado pelo ótimo local (Moda 1,0). Apenas com $\epsilon = 1,5$, o HC ganha energia suficiente para ultrapassar a depressão central e atingir o topo global (Moda 2,0, Média 1,9591). A LRS e o GRS, por realizarem amostragem estocástica de maior amplitude, localizam a região do pico global com maior facilidade (Moda 2,0 para ambos).
- Para as funções multimodais e complexas (**Funções 3 e 4**), perturbações curtas limitam o HC em mínimos locais distantes do centro. A elevação de ϵ para 1,0 permite ao HC aproximar-se substancialmente do ótimo central da Ackley (Moda 0,1 na F3) e da Rastrigin (Moda 1,2 na F4).

- **Eficiência Comparativa dos Métodos:**

- O **Hill Climbing** é altamente eficiente quando a perturbação ϵ está calibrada com a topologia do problema, agindo como um otimizador de descida/subida rápida.

- O **LRS** mostra-se a alternativa mais equilibrada e consistente em problemas unimodais ou com bacias amplas, superando o HC em cenários onde o ajuste fixo de ϵ é inadequado.
- O **GRS** possui baixa eficiência de sintonia fina, atuando como um amostrador global de baixa convergência de precisão, contudo é útil para escapar de ótimos locais amplos em funções como a F2.

• **Impacto da Multimodalidade:**

- A análise empírica revela uma clara correlação inversa: quanto mais multimodal o problema (como na Rastrigin e na senoidal oscilatória F6), pior é o desempenho final médio do Hill Climbing e do LRS, os quais se encontram frequentemente presos em ótimos locais da superfície.
- Particularmente na **Função 6**, a alta densidade de vales e picos faz com que seja realisticamente impossível atingir a melhor moda global utilizando apenas o algoritmo Hill Climbing convencional. Para convergir ao pico global com tal método, o ponto de partida aleatório do algoritmo precisaria coincidir com a bacia de atração do ótimo principal, o que demandaria uma sorte astronômica na inicialização stocástica, evidenciando as severas restrições dos algoritmos de busca estritamente local em superfícies altamente complexas.

As Figuras 1 e 2 ilustram a convergência e a trajetória de busca dos três métodos na Função 1 com $\epsilon = 2,0$, revelando a descida parabólica linearizada do HC, o caminho estocástico difuso do LRS e a amostragem dispersa do GRS. As Figuras 3 e 4 exibem o mesmo comportamento para a Função 3 (Ackley) com $\epsilon = 1,0$.




Figura 1. Histórico de aptidão para a Função 1 (Esférica) com $\epsilon = 2,0$ e $\sigma = 0,5$ (HC, LRS e GRS).




Figura 2. Trajetória tridimensional da busca local sobre a superfície da Função 1 (HC, LRS e GRS).



Figura 3. Histórico de aptidão para a Função 3 (Ackley) com $\epsilon = 1,0$ e $\sigma = 0,5$ (HC, LRS e GRS).




Figura 4. Trajetória tridimensional da busca local sobre a superfície da Função 3 (HC, LRS e GRS).

B. Etapa 2: Resultados e Análises Meta-heurísticas

1) 2.1: Resultados para as 8-Rainhas: A Têmpera Simulada obteve sucesso integral na busca espacial, localizando todas as 92 soluções globais distintas possíveis. O histórico de descoberta de novas soluções ao longo das rodadas é exibido na Figura 5.




Figura 5. Curva de descoberta cumulativa de soluções únicas das 8-Rainhas.

O custo computacional total acumulado e a eficiência da têmpera estão descritos na Tabela I. O algoritmo consumiu em média apenas 557,3 iterações por run (máximo de 1000) devido à parada antecipada no ótimo local/global. A representação física da primeira solução obtida é esboçada na Figura 6.

Tabela III
MÉTRICAS DO SIMULATED ANNEALING NO PROBLEMA DAS 8-RAINHAS

Métrica de Desempenho	Valor Obtido
Tempo total de execução	6,38 s
Total de rodadas executadas (Runs)	809
Total de avaliações/iterações	450.882
Média de iterações por rodada	557,3
Custo computacional médio por solução única	69,44 ms




Figura 6. Visualização do posicionamento das rainhas para uma das soluções obtidas.

2) 2.2: *Resultados para o Caixeiro Viajante 3D (Drone)*: A modelagem do GA com base de dados real revelou convergência consistente para rotas subótimas de transporte. O melhor traçado gerado pelo drone para cobrir os 40 pontos da região 1 e retornar à origem é ilustrado em 3D na Figura 7.




Figura 7. Trajetória tridimensional otimizada do drone para visitação dos pontos do Grupo 1.

A análise comparativa do elitismo baseada nas 30 rodadas de Monte Carlo é apresentada na Tabela II. Ao contrário do esperado teoricamente, a ausência de elitismo permitiu maior diversidade genética na população e resultou em um custo médio final ligeiramente inferior (554,70 m contra 565,03 m), assim como um menor custo absoluto obtido (527,26 m contra 529,33 m).

Tabela IV
MÉTRICAS ESTATÍSTICAS COMPARATIVAS DO GA ($R = 30$ RODADAS)

Métrica de Desempenho	Com Elitismo ($N_e = 5$)	Sem Elitismo
Distância Média de Rota (Custo Médio)	565,03 m	554,70 m
Melhor Distância Absoluta Encontrada	529,33 m	527,26 m
Média de Gerações até Parada	153,5	141,9
Moda de Gerações de Parada	92	103

O comportamento dinâmico de convergência média do custo do melhor indivíduo ao longo das gerações pode ser observado na Figura 8. Percebe-se que ambos os métodos estabilizam o decaimento em torno de 150 gerações, corroborado pelo histograma das gerações em que a parada antecipada ocorreu (Figura 9).




Figura 8. Comparação de convergência média com e sem elitismo.




Figura 9. Distribuição de gerações necessárias para acionamento do critério de parada antecipada.

3) 2.3: *Resultados para a Função Rastrigin*: A análise de convergência do Algoritmo Genético Não-Canônico para diferentes populações é apresentada na Figura 10. Os resultados médios consolidados ao longo das 5 simulações executadas constam na Tabela III.




Figura 10. Histórico de convergência do GA Não-Canônico para diferentes populações (escala logarítmica).

Tabela V
ANÁLISE COMPARATIVA E CUSTO COMPUTACIONAL (RASTRIGIN $n = 50$)

Algoritmo	Custo Médio	Tempo Médio	Custo de Armazenamento
GA Não-Canônico (População = 20)	252,88	0,180 s	$O(N_{pop} \cdot n)$
GA Não-Canônico (População = 50)	188,83	0,460 s	$O(N_{pop} \cdot n)$
GA Não-Canônico (População = 100)	150,37	0,936 s	$O(N_{pop} \cdot n)$
GA Não-Canônico (População = 150)	158,26	1,427 s	$O(N_{pop} \cdot n)$
Têmpera Simulada (SA Contínua)	204,91	0,342 s	$O(n)$

A análise empírica revela que aumentar o tamanho da população melhora significativamente a aptidão média até estabilizar em $N = 100$. A população de 150 indivíduos exige mais tempo computacional, contudo não traz melhorias na convergência média, sugerindo que o equilíbrio ideal está no entorno de 100 indivíduos.

A comparação direta de desempenho entre o GA ($N_{pop} = 100$) e o Simulated Annealing está disposta no gráfico de evolução por avaliações da função objetivo (Figura 11). Embora a Têmpera Simulada possua tempo de processamento inferior por rodada (apenas 0,342 s comparados a 0,936 s do GA), o GA Não-Canônico com SBX e mutação Gaussiana obteve um custo médio de convergência final substancialmente menor (150,37 contra 204,91).

O aspecto do consumo de memória constitui um ponto crucial para sistemas embarcados. Enquanto o GA exige o armazenamento de toda a população ($N_{pop} \times 50$ valores flutuantes), a Têmpera Simulada necessita guardar apenas o vetor atual, o candidato gerado e o melhor vetor da execução (3×50 valores flutuantes), o que justifica sua aplicação em cenários com restrições severas de memória física apesar da menor robustez contra mínimos locais secundários da Rastrigin.




Figura 11. Curva de convergência por número de avaliações: GA contra Simulated Annealing.

IV. CONCLUSÕES

Os experimentos computacionais confirmaram a validade e a eficiência das implementações meta-heurísticas de busca local e algoritmos evolutivos na resolução dos problemas propostos.

Na resolução das 8-Rainhas, o Simulated Annealing mostrou-se extremamente rápido e dinâmico, sendo capaz de explorar eficientemente a vizinhança e descobrir todas as 92 soluções globais em pouco tempo de execução. Para a resolução do Caixeiro Viajante 3D na base real de pontos, o Algoritmo Genético encontrou rotas de entrega subótimas satisfatórias, exibindo estabilização ao redor de 150 gerações. Por fim, a otimização contínua da função Rastrigin ilustrou o contraste de desempenho e armazenamento entre Algoritmos Genéticos e busca local: o GA não-canônico provou-se mais apto a escapar de ótimos locais na superfície complexa da Rastrigin ao custo de maior pegada em memória física, consolidando as duas estratégias como complementares no escopo da Inteligência Artificial Computacional.

REFERÊNCIAS

- [1] P. C. S. Barbosa, “Trabalho Computacional AV3: Busca e Otimização Meta-heurística,” UNIFOR, 2026.